ENTREGA 1 · MODELAGEM DO PROBLEMA

Da posse de bola ao gol

O problema de converter uma posse de bola em gol formulado como um Processo de Decisão de Markov

Cauê Fernando e Paulo Fernando · 29 de outubro de 2026

Este documento detalha a modelagem apresentada nos slides da Entrega 1. **O agente é o jogador com a bola.** Ele observa um estado de cerca de 100 variáveis contínuas (posições e velocidades da bola e dos 22 jogadores, além do contexto do jogo), escolhe entre **31 ações discretas** e recebe **+1 apenas quando a posse termina em gol**. Com essa recompensa e sem desconto, o valor de cada estado é exatamente a probabilidade de a posse virar gol, que é o que o problema pede para maximizar.

1 O problema

> *Dado um time de futebol em posse de bola, determinar a sequência ótima de ações (passes, chutes, dribles, movimentações) que maximize a probabilidade de converter a posse em gol, considerando as posições dos 22 jogadores, o contexto do jogo e as transições probabilísticas do ambiente.*

Uma posse de bola é uma sequência de decisões. A cada toque, quem está com a bola escolhe entre passar, chutar, driblar, conduzir ou segurar, e cada escolha muda a situação do jogo. O resultado de cada escolha é incerto: o mesmo passe pode chegar ou ser interceptado, dependendo de onde estão e de como reagem os adversários. E o que realmente importa, o gol, só aparece no fim da jogada, às vezes depois de dez ou vinte toques.

Essas três características (decisões em sequência, resultado incerto e recompensa atrasada) definem um problema de aprendizado por reforço. Por isso o modelamos como um **Processo de Decisão de Markov** (MDP), a estrutura matemática padrão dessa área (Sutton e Barto, 2018).

Sequência ótima ou política ótima?

Como o ambiente é aleatório, não existe uma sequência fixa de ações que seja sempre a melhor: se o passe planejado for desviado, o plano precisa mudar. O que buscamos é uma **política** π, uma regra que diz qual ação tomar em cada situação. A "sequência ótima" do enunciado é a que surge quando o time segue a política ótima π^*, jogada após jogada.

2 Formulação como MDP

Um MDP é definido por cinco elementos. A tabela resume como cada um aparece neste problema; as seções seguintes detalham cada linha.

Elemento	Símbolo	Nesta modelagem
Estados	S	Bola, 22 jogadores, posse e contexto do jogo: cerca de 100 variáveis contínuas (Seção 4)
Ações	A	31 ações discretas do jogador com a bola (Seção 5)
Transições	$P(s' \mid s, a)$	Dinâmica do jogo e reação do adversário; desconhecida pelo agente (Seção 5.1)
Recompensa	$R(s, a, s')$	+1 no gol, 0 em qualquer outro passo (Seção 6)
Desconto	γ	1, ou 0,99 para favorecer jogadas rápidas (Seção 6.1)

A interação acontece em passos. No passo t, o agente observa o estado s_t, escolhe uma ação a_t, e o ambiente responde com uma recompensa r_{t+1} e um novo estado s_{t+1}. O objetivo é encontrar a política que maximiza o retorno esperado:

$$\pi^* = \arg\max_{\pi} \mathbb{E}_{\pi}\left[\sum_{t=0}^{T-1} \gamma^t \, r_{t+1} \right]$$

em que T é o passo em que a posse termina.

3 Ambiente

O ambiente é a partida: um campo de 105 × 68 m com os 22 jogadores e a bola. Neste documento, x mede o comprimento do campo, de 0 a 105 m, no sentido do ataque, e y mede a largura, de 0 a 68 m.

Tempo discreto

O jogo é contínuo, mas o agente decide em instantes discretos. Há duas opções: passos fixos de cerca de 0,1 s, que acompanham bem o movimento dos jogadores, ou um passo por evento (um toque na bola), que reduz o número de decisões por posse. Na segunda opção, ações como conduzir e segurar duram um intervalo fixo antes da próxima decisão.

Episódio = uma posse

Cada episódio é uma posse de bola. Ele começa quando o time recupera a bola e termina em uma de três situações:

- **gol marcado;**
- **perda da posse:** interceptação, desarme, bola fora ou falta;
- **limite de tempo** atingido.

O limite de tempo garante que todo episódio termina, o que é necessário para usar desconto $\gamma = 1$ (Seção 6).

O adversário faz parte do ambiente

O time adversário não é modelado como um segundo agente: seu comportamento é tratado como parte da dinâmica do jogo, e é ele a principal fonte de incerteza nas transições. Se o adversário também aprendesse, o problema viraria um jogo entre dois agentes, o que está fora do escopo desta entrega.

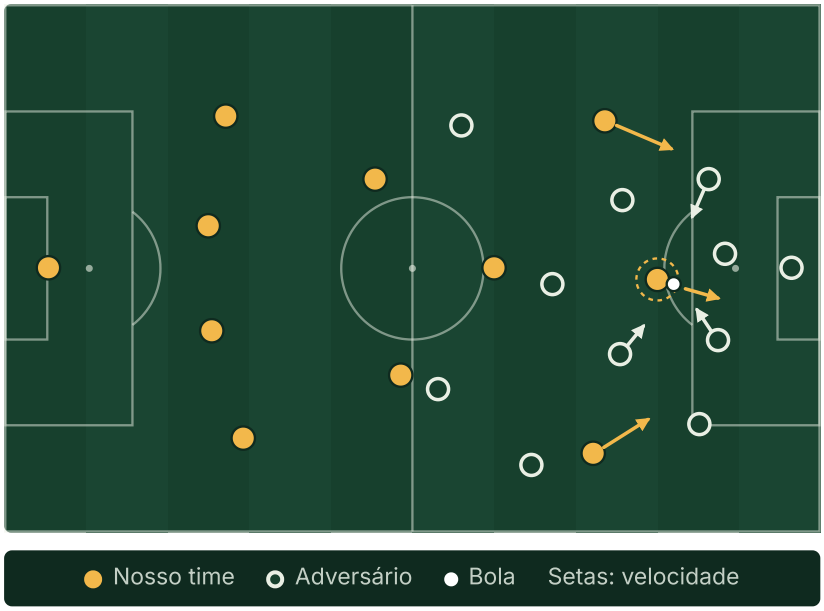


Figura 1. Um estado do jogo: posições dos 22 jogadores, a bola (com o jogador destacado pelo círculo tracejado) e alguns vetores de velocidade. As posições são ilustrativas.

4 Estado

O estado s_t reúne tudo o que o agente observa no passo t:

Grupo	Informação	Dimensão
Bola	posição (x, y, z) e velocidade (v_x, v_y, v_z)	6
Companheiros (11)	posição (x, y) e velocidade (v_x, v_y) de cada um	44
Adversários (11)	posição (x, y) e velocidade (v_x, v_y) de cada um	44
Posse	qual jogador está com a bola	1
Contexto	saldo do placar, tempo restante e modo de jogo (bola rolando, escanteio, falta, lateral)	~3
Total	**variáveis contínuas**	**≈ 100**

A bola tem coordenada z porque bolas altas, como passes longos e cruzamentos, se comportam de forma diferente: passam por cima dos marcadores e só podem ser disputadas quando descem. O saldo do placar e o tempo restante mudam o quanto vale a pena arriscar, e o modo de jogo diz se a bola está rolando ou parada.

4.1 Por que o estado é markoviano

Um estado tem a propriedade de Markov quando o futuro depende apenas do presente, e não do caminho até ele:

$$P(s_{t+1} \mid s_t, a_t) = P(s_{t+1} \mid s_0, a_0, s_1, a_1, \ldots, s_t, a_t)$$

As velocidades são o que garante essa propriedade. Imagine dois atacantes no mesmo ponto do campo: um parado e outro em disparada rumo à área. Se o estado guardasse só as posições, os dois casos seriam idênticos, mas o próximo estado seria muito diferente; para distingui-los, seria preciso olhar os instantes anteriores, ou seja, o histórico. Com posições e velocidades, o estado atual já descreve a dinâmica da jogada, e o próximo estado depende apenas de s_t e da ação a_t.

É uma aproximação: o cansaço dos jogadores, a habilidade de cada um e a intenção do adversário não estão no estado. O efeito desses fatores é tratado como aleatoriedade nas transições.

4.2 Observabilidade

Supomos **observabilidade total**: o agente conhece a posição e a velocidade de todos, como nos dados de rastreamento (*tracking*) de partidas profissionais. As intenções do adversário não são observáveis e entram como estocasticidade da transição $P(s' \mid s, a)$. Se o agente enxergasse apenas o que o jogador com a bola vê, o problema seria parcialmente observável (um POMDP).

4.3 Consequência para o aprendizado

Com cerca de 100 variáveis contínuas, o número de estados possíveis é infinito na prática, e não dá para guardar um valor por estado em uma tabela. As próximas entregas precisarão de aproximação de funções (por exemplo, uma rede neural que recebe o estado e estima o valor de cada ação) ou de uma discretização do campo em zonas.

---

5 Ações

Quem é o agente

O agente é **o jogador com a bola**. Quando ele passa, o controle vai para quem recebe. Os companheiros sem bola seguem uma política fixa de movimentação: ocupar espaços e oferecer linha de passe.

A escolha é deliberada. Controlar os 11 jogadores ao mesmo tempo multiplicaria as opções: só para mover os 10 jogadores sem bola em 8 direções seriam 8^{10}, mais de um bilhão de combinações por passo. Com um jogador por vez, o espaço de ações fica pequeno.

As 31 ações

Ação	Descrição	Qtd.
`passe_curto(j)`	passe rasteiro para o companheiro *j*	10
`passe_longo(j)`	bola alta ou cruzamento para o companheiro *j*	10
`chute`	finalização ao gol	1
`conduzir(dir)`	avançar com a bola em uma de 8 direções	8
`driblar`	tentar passar pelo marcador mais próximo	1
`segurar`	proteger a bola e esperar a movimentação dos companheiros	1
Total	**ações discretas**	**31**

As movimentações do enunciado aparecem de duas formas: a condução move o jogador com a bola, e a política fixa move os demais. A ação `segurar` existe justamente para dar tempo a essa movimentação: o jogador protege a bola enquanto os companheiros se desmarcam.

Ações discretas simplificam o aprendizado, mas perdem detalhes como a força e o ângulo exatos de um passe. Esse refinamento pode vir depois, se for necessário.

5.1 Transições probabilísticas

A função de transição $P(s' \mid s, a)$ dá a probabilidade de cada próximo estado. O agente não a conhece: aprende seus efeitos jogando. Alguns exemplos do que ela captura:

- **Passe:** a probabilidade de sucesso cai com a distância e com adversários próximos da linha do passe.
- **Chute:** vira gol com probabilidade próxima do xG (*expected goals*, a chance de um chute virar gol, estimada a partir de chutes parecidos), que depende de distância, ângulo e pressão do marcador.
- **Drible:** o sucesso depende da distância até o marcador e de quantos marcadores há por perto.
- **Ruído:** mesmo quando a ação dá certo, a posição final da bola e dos jogadores varia.

Assim, um passe curto para o companheiro *j* leva a dois tipos de próximo estado: o passe chega e *j* passa a ser o agente, ou o passe é interceptado e o episódio termina.

6 Recompensas

Evento	Recompensa	Episódio
Gol marcado	**+1**	termina
Perda de posse (interceptação, desarme, bola fora, falta) ou fim do tempo	0	termina
Qualquer outro passo (passe certo, condução, drible bem-sucedido)	0	continua

A recompensa é **esparsa**: só o gol rende algo.

6.1 O valor de um estado é a probabilidade de gol

Como só o gol dá recompensa, e ele acontece no máximo uma vez por posse, o retorno de um episódio com $\gamma = 1$ é:

$$G = \sum_{t=0}^{T-1} r_{t+1} = 1 \text{ se a posse termina em gol, e 0 caso contrário}$$

O valor de um estado é o retorno esperado a partir dele, seguindo a política π:

$$V^{\pi}(s) = \mathbb{E}_{\pi}[G \mid s_0 = s] = 1 \cdot P(\text{gol} \mid s, \pi) + 0 \cdot (1 - P(\text{gol} \mid s, \pi)) = P(\text{gol} \mid s, \pi)$$

Maximizar o retorno esperado é, portanto, maximizar a probabilidade de converter a posse em gol, exatamente o que o enunciado pede. O valor ótimo $V^*(s) = \max_{\pi} P(\text{gol} \mid s, \pi)$ é a melhor chance de gol possível a partir de s.

> **Por que não punir a perda da bola?**
> Perder a bola já encerra o episódio sem gol e, com ele, todo o retorno futuro; o agente aprende a evitar isso sem punição extra. Uma penalidade negativa mudaria o objetivo: como um chute para fora também é perda da posse, o agente passaria a chutar menos do que deveria para não ser punido, mesmo quando o chute é a melhor chance de gol.

Desconto $\gamma < 1$

Com $\gamma < 1$ (por exemplo, 0,99), um gol no passo T vale γ^T, e o valor passa a ser $\mathbb{E}[\gamma^T \cdot \mathbb{1}\{\text{gol}\}]$: gols que demoram valem menos. O agente passa a preferir jogadas rápidas, antes que a defesa se organize. O preço é que o valor deixa de ser exatamente a probabilidade de gol.

6.2 Exemplo: por que um passe pode valer mais que um chute

A equação de Bellman relaciona o valor de uma ação com os estados a que ela leva:

$$Q(s, a) = \sum_{s'} P(s' \mid s, a) \, [\, r + \gamma \, V(s') \,]$$

Considere um atacante na entrada da área, marcado, com um companheiro livre dentro dela. Os números abaixo são **hipotéticos**, escolhidos só para ilustrar a conta (com $\gamma = 1$):

Ação	Resultados possíveis	$Q(s, a)$
Chute	gol com probabilidade 0,08; caso contrário, fim da posse	0,08 × 1 = **0,08**
Passe curto para o companheiro livre	chega com probabilidade 0,70, e com ele livre na área $V(s')$ = 0,30; interceptado com probabilidade 0,30	0,70 × 0,30 = **0,21**
Segurar	mantém a bola com probabilidade 0,85, e $V(s')$ = 0,10	0,85 × 0,10 = **0,085**

Mesmo com o risco de perder a bola, o passe dá a maior chance de gol: 21% contra 8% do chute imediato. A política ótima escolhe a ação que maximiza a probabilidade de gol considerando o que vem depois, e não a chance imediata. É esse raciocínio, repetido em cada estado, que gera a sequência ótima de ações.

6.3 Recompensa auxiliar (*reward shaping*)

O problema prático da recompensa esparsa é que o gol é raro: no início do treino, quando o agente joga quase ao acaso, o +1 quase nunca aparece e não há sinal para aprender. Para acelerar, somamos à recompensa um termo baseado em potencial:

$$F(s, s') = \gamma\,\Phi(s') - \Phi(s)$$

em que Φ(*s*) mede a ameaça da posição da bola e cresce à medida que ela se aproxima do gol. Duas opções são o *expected threat* (xT), que estima a chance de a posse virar gol a partir de cada zona do campo (Singh, 2018), ou simplesmente o negativo da distância ao gol. Na prática, o agente ganha um bônus ao avançar a bola para zonas perigosas e perde ao recuar.

Esse formato **não altera a política ótima** (Ng, Harada e Russell, 1999). Com γ = 1, a razão é direta: somando F ao longo do episódio, os termos se cancelam aos pares e sobra

$$\sum_{t=0}^{T-1} F(s_t, s_{t+1}) = \Phi(s_T) - \Phi(s_0) = -\Phi(s_0)$$

tomando Φ = 0 nos estados terminais. O bônus total depende só de onde a posse começou e é igual para qualquer política; a comparação entre políticas, e portanto a melhor delas, não muda. Um recuo que prepara um gol continua valendo a pena: o que o agente perde ao recuar, recupera ao avançar de novo.

7 Simplificações e limitações

- **Companheiros sem bola** seguem uma política fixa; o agente não aprende a movimentação deles.
- **Ações discretas:** a força e a direção do passe são aproximadas.
- **Observabilidade total,** como em dados de *tracking*; um jogador real enxerga menos.
- **Adversário fixo:** seu comportamento está embutido nas transições e não se adapta ao agente.
- **Jogadores tratados como iguais:** diferenças de habilidade aparecem só como ruído nas transições.

Referências

NG, A. Y.; HARADA, D.; RUSSELL, S. Policy invariance under reward transformations: theory and application to reward shaping. In: *Proceedings of the 16th International Conference on Machine Learning* (ICML), 1999. p. 278–287.

SINGH, K. *Introducing Expected Threat (xT)*. 2018. Disponível em: https://karun.in/blog/expected-threat.html.

SUTTON, R. S.; BARTO, A. G. *Reinforcement Learning: An Introduction*. 2. ed. Cambridge, MA: MIT Press, 2018.